



Universidad Nacional de Rosario

Facultad de Ciencias Exactas, Ingeniería y Agrimensura

Escuela de Ingeniería Electrónica

ANTEPROYECTO

Sistema de Gestión de Inventario con IA para Kits de Robótica

SANSONI, Uriel Isidro

S-5494/1

urisansoni@gmail.com

Tutor: Ing. Sergio Geninatti

9 de marzo de 2026

Índice

1. Introducción	1
2. Objetivos	3
3. Alcance y limitaciones del sistema	4
4. Áreas involucradas	5
5. Marco teórico	6
5.1. Procesamiento digital de imágenes	6
5.1.1. Forma clásica	6
5.1.2. Redes neuronales - Machine Learning	7
5.1.3. Detección de objetos en visión artificial	11
5.1.4. Frameworks	12
5.1.5. Plataforma Roboflow	13
5.1.6. Hardware	15
5.2. Calibración cámara-robot	17
5.3. Sistema de alimentación y posicionamiento de piezas	18
5.3.1. Sistema de posicionamiento por vibración	18
5.3.2. Sistema de cinta transportadora motorizada	19
5.3.3. Consideraciones de selección	20
5.4. Sistema de selector/sorter	20
5.4.1. Robot pick and place	20
5.4.2. Diseño mecanismo dedicado	21
5.4.3. Kit VEX IQ	21
5.4.4. Elección y Justificación	22
5.5. Interfaces de comunicación del sistema	23
5.5.1. Comunicación con el manipulador robótico	23
5.5.2. Control del sistema de transporte	23
5.5.3. Procesamiento de resultados de inferencia	24
6. Plan de acción	25

6.1.	Diagrama del sistema	25
6.1.1.	Adquisición y procesamiento de imágenes	25
6.1.2.	Detección de objetos y clasificación mediante modelo de inteligencia artificial	26
6.1.3.	Integración y decisión de control	26
6.1.4.	Ejecución de la acción	26
6.2.	Entregables	27
6.2.1.	Documentación Técnica y Académica	27
6.2.2.	Productos de Software y Modelos	27
6.2.3.	Prototipo Funcional	28
6.2.4.	Materiales Complementarios	28

1. Introducción

En entornos educativos técnicos y laboratorios de formación en ingeniería, la gestión y organización de componentes físicos constituye una tarea recurrente y crítica. La manipulación frecuente de piezas de diferentes geometrías, tamaños y funciones genera desorden, pérdidas parciales de inventario y errores en el conteo manual, afectando la eficiencia operativa y la disponibilidad de recursos para las actividades formativas.

Esta problemática se vuelve particularmente evidente en el caso de los kits de robótica educativa. Como puede observarse en la Fig. 1, un kit completo incluye una gran diversidad de componentes mecánicos, estructurales, electrónicos y de transmisión, cada uno con cantidades específicas que deben mantenerse constantes para asegurar su correcto uso. La variedad de vigas, conectores, engranajes, ejes, sensores y accesorios implica no solo una tarea de organización espacial, sino también un control cuantitativo preciso.

Las fotografías reales del kit ordenado (Fig. 2) evidencian que cada pieza posee un compartimento asignado dentro de la bandeja, lo que establece implícitamente un modelo de inventario ideal. Sin embargo, tras actividades prácticas, los componentes suelen almacenarse de manera desorganizada en la caja principal, requiriendo un proceso manual de clasificación y conteo que resulta tedioso, repetitivo y propenso a errores humanos, especialmente cuando se administran múltiples kits en simultáneo.


Frente a esta situación, surge la necesidad de desarrollar un sistema automatizado capaz de asistir en el proceso de identificación, clasificación y reorganización de piezas. La integración de técnicas de visión artificial, aprendizaje automático y manipulación robótica permite abordar esta tarea desde un enfoque tecnológico avanzado, alineado con los principios de automatización inteligente e industria 4.0.

En este contexto, el presente proyecto propone el diseño y desarrollo de un sistema autónomo para la identificación y clasificación de piezas pertenecientes a kits de robótica educativa (caso de estudio: VEX IQ), utilizando una red neuronal convolucional implementada en un sistema embebido e integrada con un manipulador robótico tipo pick-and-place. El sistema deberá reconocer cada componente, determinar su posición espacial y manipularlo físicamente para depositarlo en su compartimento correspondiente, generando además un registro digital del proceso realizado.

De esta manera, el proyecto materializa la convergencia entre procesamiento digital de imágenes, inteligencia artificial embebida, control robótico y sistemas electrónicos distribuidos, ofreciendo una solución tecnológica concreta a una problemática real del ámbito educativo técnico.



(a) Caja del Kit



(b) Bandeja del Kit

Fig. 2: Fotos reales del kit ordenado

2. Objetivos

El objetivo general del presente proyecto es diseñar y desarrollar un sistema automatizado capaz de identificar, clasificar y manipular piezas pertenecientes a kits de robótica educativa, integrando técnicas de visión artificial, inteligencia artificial embebida y control robótico.

Para alcanzar este objetivo general, el sistema deberá cumplir con las siguientes funciones específicas:

1. **Clasificación automática de piezas:** El sistema deberá permitir que el usuario deposite las piezas del kit en un contenedor de alimentación, desde donde serán transportadas individualmente hacia una zona de inspección. Mediante un modelo de visión artificial basado en redes neuronales convolucionales, el dispositivo identificará el tipo

de pieza y determinará su posición espacial para su posterior manipulación.

2. **Conteo preciso de componentes:** A medida que las piezas sean clasificadas y reubicadas en sus compartimentos correspondientes, el sistema deberá llevar un conteo automático de cada tipo de componente procesado, permitiendo verificar el estado del inventario del kit.
3. **Registro digital del inventario generado:** El sistema deberá generar un registro digital del proceso realizado, almacenando la información correspondiente al tipo y cantidad de piezas clasificadas durante cada ciclo de operación. Dicho registro podrá implementarse mediante archivos estructurados u otros mecanismos de almacenamiento persistente acordes al alcance del proyecto.
4. **Optimización del tiempo de proceso:** El diseño integral del sistema deberá orientarse a minimizar el tiempo total requerido para completar el ciclo de clasificación y reorganización de las piezas, garantizando una operación eficiente y repetible.
5. **Evaluación de detección de piezas no correspondientes (objetivo complementario):** Como línea exploratoria, se analizará la factibilidad de detectar piezas que no correspondan al inventario estándar del kit o que presenten configuraciones anómalas, evaluando los desafíos técnicos asociados a esta problemática.

3. Alcance y limitaciones del sistema

El presente proyecto tiene como objetivo desarrollar un prototipo funcional que demuestre la viabilidad de un sistema automatizado para la detección, manipulación y organización de piezas pertenecientes a kits de robótica educativa. En este contexto, el sistema se diseñará considerando un conjunto representativo de piezas seleccionadas del kit VEX IQ, con el fin de validar el enfoque propuesto sin requerir la cobertura completa de todos los componentes disponibles.

El sistema estará orientado a procesar piezas individuales dentro de una zona de inspección controlada, donde las condiciones de iluminación, fondo y posicionamiento de los objetos podrán mantenerse relativamente constantes. Este enfoque permite reducir la complejidad del problema de visión artificial y facilita la evaluación experimental del modelo de detección.

Asimismo, el proceso de manipulación se realizará bajo el supuesto de que las piezas llegan de forma individual a la zona de captura de imágenes, evitando situaciones en las que

múltiples objetos se superpongan o dificulten la correcta detección.

Es importante destacar que el sistema desarrollado tendrá carácter experimental y demostrativo. Si bien el diseño busca aproximarse a una solución aplicable en entornos educativos reales, no se pretende en esta etapa alcanzar niveles de robustez propios de sistemas industriales de clasificación automatizada.

Las limitaciones asociadas al prototipo pueden incluir factores como variaciones en la iluminación, oclusión parcial de piezas, errores de detección del modelo de visión artificial o imprecisiones en la manipulación robótica. No obstante, estas limitaciones forman parte natural del proceso de desarrollo y constituyen oportunidades de mejora para futuras iteraciones del sistema.

4. Áreas involucradas

La realización del presente proyecto requiere la integración interdisciplinaria de distintas áreas de la ingeniería, cada una aportando conocimientos y herramientas fundamentales para el desarrollo del sistema propuesto. Las principales áreas involucradas son las siguientes:

Electrónica

Responsable del diseño e integración de los sistemas de control y comunicación entre los distintos módulos que componen el dispositivo. Incluye la gestión de interfaces físicas, alimentación, control de actuadores, comunicación serial entre dispositivos embebidos y coordinación del sistema de transporte de piezas.

Procesamiento Digital de Imágenes e Inteligencia Artificial

Encargada de la adquisición, preprocesamiento y análisis de imágenes capturadas en la zona de inspección. Comprende el desarrollo y despliegue de un modelo de red neuronal convolucional para la identificación automática de piezas, así como la estructuración de la información resultante para su utilización en la toma de decisiones del sistema.

Mecánica

Fundamental para el diseño del sistema físico de alimentación y transporte de piezas. Esta área también contempla el estudio de la disposición geométrica de los compartimentos del kit y la interacción física entre los componentes manipulados y el sistema robótico.

Robótica y Control de Manipuladores

Involucra la integración del sistema de visión con el manipulador robótico. Incluye la transformación de coordenadas desde el sistema de referencia de la imagen al sistema cartesiano del robot, la generación de trayectorias, la ejecución de comandos de movimiento y la sincronización entre percepción y acción.

5. Marco teórico

5.1. Procesamiento digital de imágenes

5.1.1. Forma clásica

El **procesamiento digital de imágenes (PDI)** se refiere al conjunto de técnicas que se aplican a las imágenes digitales para mejorar, extraer información o prepararlas para un análisis posterior. Los métodos clásicos se basan en operaciones matemáticas y estadísticas definidas.

La **convolución** es el corazón del procesamiento de imágenes clásico. Es una operación matemática que permite modificar una imagen aplicando un kernel (una matriz pequeña) sobre cada píxel de la imagen.

El kernel se desliza sobre la imagen, y en cada posición, se multiplica sus valores por los píxeles subyacentes de la imagen. La suma de estas multiplicaciones reemplaza al píxel central.




Fig. 3: Ejemplo de convolución con filtro "sharpen"

Y de esta manera podemos obtener resultados muy interesantes ya que nos permite

limpiar el ruido a las imagenes, podemos corregir borrosidades, realzar y detectar bordes y muchas otras cuestiones que nos ayudan a acercarnos al objetivo.




Fig. 4: Ejemplos de filtros de convolución.

Luego, tenemos herramientas para poder segmentar la imagen y dividirla en regiones de interés, como la umbralización que nos permite separar el fondo del objeto en interés.

Por último, podemos extraer características propias de cada objeto con ayuda de descriptores geométricos, histogramas de densidad y descriptores de forma.

5.1.2. Redes neuronales - Machine Learning

Una **red neuronal artificial (RNA)** es un modelo computacional inspirado en la estructura y funcionamiento de las redes neuronales biológicas. Está compuesta por unidades de procesamiento (neuronas) interconectadas organizadas en capas, que transforman los

datos de entrada mediante operaciones matemáticas para producir una salida. La capacidad de aprendizaje de estos modelos reside en el ajuste iterativo de los pesos sinápticos que conectan las neuronas, mediante algoritmos de optimización como el descenso de gradiente.

La unidad fundamental de procesamiento es la **neurona artificial**, un modelo matemático que realiza operaciones secuenciales. Primero, calcula una **combinación lineal ponderada** de sus entradas; cada **señal de entrada** x_i se multiplica por un **peso sináptico** w_i , el cual cuantifica su importancia relativa. A esta suma se le añade un parámetro de **sesgo (bias)** b , un término de ajuste independiente que permite desplazar la función de activación para mejorar la adaptabilidad del modelo. Matemáticamente, esta operación se expresa como $z = \sum_{i=1}^n (w_i \cdot x_i) + b$. Posteriormente, el valor z es transformado por una **función de activación no lineal** $\sigma(z)$. Esta función es crucial, ya que introduce la no linealidad necesaria para que la red pueda aprender patrones complejos y representar relaciones no lineales en los datos. La salida final de la neurona es $a = \sigma(z)$.




Fig. 5: Esquema de una neurona artificial

Diversas funciones de activación se emplean según el contexto. La **función Sigmoide**, que comprime la salida en el rango $(0, 1)$, fue históricamente popular y resulta adecuada para capas de salida en problemas de clasificación binaria, donde su salida puede interpretarse como una probabilidad. En la actualidad, la función ReLU (Rectified Linear Unit), definida como $f(z) = \max(0, z)$, se ha establecido como estándar para las capas ocultas debido a su eficiencia computacional. Existen también variantes como Leaky ReLU y Tanh (tangente hiperbólica), así como la función Softmax, específicamente diseñada para capas de salida en problemas de clasificación multi-clase, ya que normaliza las salidas para representar una distribución de probabilidad.




Fig. 6: Funciones de activación

Estas neuronas se organizan en estructuras paralelas denominadas **capas**, formando una arquitectura de procesamiento secuencial. La **capa de entrada** recibe los datos crudos o características preprocesadas, distribuyéndolos hacia la red. Las **capas ocultas** constituyen el núcleo computacional; cada neurona en estas capas recibe las salidas de la capa anterior, calcula su propia activación y la propaga a la siguiente. Finalmente, la **capa de salida** produce el resultado de la red, cuya función de activación se elige en función de la tarea específica.




Fig. 7: Esquema de una red neuronal artificial

El proceso de aprendizaje automatizado de la red, mediante el cual ajusta sus pesos y sesgos, es lo que le permite mapear relaciones complejas entre entradas y salidas, constituyendo la base de su poder de representación.

Existen diversas arquitecturas de RNA, cada una adecuada para tipos específicos de problemas:

Redes Densamente Conectadas (Fully Connected):

Estas redes, también conocidas como perceptrones multicapa, consisten en capas donde cada neurona está conectada a todas las neuronas de la capa siguiente. Si bien son arquitecturas versátiles, presentan limitaciones significativas al procesar datos con estructura espacial, como las imágenes, ya que requieren el aplanamiento (flattening) de la entrada, lo que conlleva una pérdida de información topológica y una explosión en la cantidad de parámetros, haciéndolas computacionalmente ineficientes para este fin.

Redes Neuronales Convolucionales (CNN):

Las CNN surgen como la arquitectura especializada para el procesamiento de datos con estructura de grid, como imágenes o secuencias temporales. Su diseño incorpora capas convolucionales que aplican operaciones de filtrado preservando las relaciones espaciales entre píxeles. Esta característica las hace inherentemente más eficientes y efectivas para tareas de visión por computadora que las redes densamente conectadas.

El núcleo de una CNN reside en sus capas convolucionales. Estas capas utilizan kernels (o filtros) que se deslizan sobre la entrada realizando una operación de convolución. A diferencia del procesamiento de imágenes clásico, donde los kernels (e.g., Sobel, Gaussiano) son definidos explícitamente por un experto, en una CNN estos kernels son parámetros que se aprenden automáticamente durante el entrenamiento. Esto permite que la red descubra por sí misma las características más relevantes para la tarea.

Las CNN construyen una representación jerárquica de los datos:

- **Capas iniciales:** Detectan patrones de bajo nivel como bordes, texturas y colores.
- **Capas intermedias:** Combinan estas características primarias para formar patrones más complejos, como formas geométricas simples.
- **Capas profundas:** Detectan entidades de alto nivel y partes semánticas de los objetos.

Operaciones complementarias como el pooling (submuestreo) confieren a la red invariancia a traslaciones y distorsiones menores, mientras que las capas totalmente conectadas finales se encargan de la clasificación basándose en las características de alto nivel extraídas.




Fig. 8: Esquema de una red convolucional

En conclusión, las CNN representan el estado del arte para problemas de clasificación y detección en imágenes, constituyendo la opción técnica más sólida y adecuada para los objetivos del presente proyecto.

5.1.3. Detección de objetos en visión artificial

En muchos problemas de visión artificial no solo es necesario identificar qué objeto aparece en una imagen, sino también determinar su ubicación dentro de la misma. Este tipo de problemas se conoce como **detección de objetos** (*object detection*).

A diferencia de los modelos de clasificación tradicionales basados en redes neuronales convolucionales, que asignan una única etiqueta a una imagen completa, los modelos de detección permiten localizar múltiples objetos dentro de una escena mediante regiones delimitadas denominadas *bounding boxes*. Cada una de estas regiones se asocia a una clase identificada y a un valor de confianza que representa la probabilidad estimada de la predicción.

En los últimos años han surgido diversas arquitecturas especializadas para esta tarea, entre las que se destacan las pertenecientes a la familia **YOLO** (*You Only Look Once*). Estos modelos permiten realizar detección de objetos en tiempo real mediante una única pasada de inferencia sobre la imagen, combinando velocidad de procesamiento con una precisión

adecuada para aplicaciones prácticas.

Las plataformas modernas de desarrollo de visión artificial, como Roboflow, utilizan internamente arquitecturas de detección basadas en redes neuronales profundas (frecuentemente derivadas de la familia YOLO), proporcionando como salida estructuras de datos que contienen tanto la clase del objeto detectado como su ubicación dentro de la imagen.




Fig. 9: Ejemplo de detección de objetos mediante bounding boxes.

5.1.4. Frameworks

En el ámbito del desarrollo de software, un framework (o entorno de trabajo) se define como una estructura conceptual y tecnológica que proporciona componentes preconstruidos, bibliotecas y herramientas estandarizadas para agilizar el desarrollo de aplicaciones. En el contexto específico del deep learning, estos entornos abstraen la complejidad matemática y algorítmica subyacente (como el cálculo de gradientes o la gestión de tensores), permitiendo a los investigadores e ingenieros focalizarse en el diseño y experimentación de modelos, en lugar de en la implementación de rutinas de bajo nivel.

Existe una variedad de frameworks en el dominio del deep learning, siendo los más destacados:

- **TensorFlow:** Desarrollado por Google, es una plataforma integral, altamente madura y ampliamente adoptada en entornos industriales. Su flexibilidad y robustez lo hacen adecuado para proyectos de diversa escala.
- **PyTorch:** Creado por Meta (Facebook), es reconocido por su diseño intuitivo y su ejecución imperativa (eager execution), que facilita la depuración y la experimentación rápida. Es muy popular en el ámbito académico.

- **Keras:** Originalmente una API de alto nivel que funcionaba sobre TensorFlow, Theano y CNTK. Su simplicidad lo convierte en una excelente opción para principiantes. Actualmente está totalmente integrado en TensorFlow (`tf.keras`).
- **Otros:** Frameworks como MXNet (Apache) o ONNX (Open Neural Network Exchange) también poseen nichos de aplicación específicos, aunque con una adopción menor comparativa.

5.1.5. Plataforma Roboflow

Para el desarrollo del sistema de visión artificial propuesto en este proyecto se utilizará la plataforma Roboflow, una herramienta especializada en el desarrollo y despliegue de modelos de visión por computadora.

Roboflow proporciona un entorno integrado que permite gestionar el flujo completo de trabajo asociado al entrenamiento de modelos de detección y clasificación de objetos. A diferencia de los frameworks tradicionales, donde el desarrollador debe implementar manualmente las distintas etapas del pipeline de aprendizaje automático, Roboflow abstrae gran parte de esta complejidad y ofrece herramientas para la preparación del dataset, el entrenamiento del modelo y la generación de sistemas de inferencia listos para su integración en aplicaciones reales.

El flujo de trabajo típico utilizando esta plataforma puede resumirse en las siguientes etapas:

1. **Recolección del dataset:** Obtención de imágenes representativas de las distintas piezas que componen el kit de robótica. Estas imágenes constituyen la base del conjunto de datos utilizado para entrenar el modelo de visión artificial.

Para garantizar la capacidad de generalización del modelo de detección, el conjunto de datos deberá incluir imágenes de las piezas capturadas bajo distintas condiciones de orientación, iluminación y posición dentro del área de inspección. Esto permite que el modelo aprenda representaciones más robustas de cada objeto y reduzca la probabilidad de errores durante la inferencia.

Asimismo, se procurará mantener un equilibrio razonable entre las distintas clases de piezas incluidas en el dataset, evitando sesgos que puedan afectar el desempeño del modelo durante la etapa de detección. El conjunto de datos será posteriormente dividido en subconjuntos de entrenamiento, validación y prueba, siguiendo prácticas habituales en el desarrollo de sistemas de aprendizaje automático.

2. **Etiquetado de imágenes:** Cada imagen es anotada manualmente mediante herramientas de etiquetado provistas por la plataforma, definiendo las clases correspondientes a cada tipo de pieza y delimitando las regiones de interés mediante cuadros delimitadores (*bounding boxes*).
3. **Preprocesamiento y aumento de datos:** Roboflow permite aplicar transformaciones automáticas sobre el dataset (rotaciones, cambios de escala, variaciones de iluminación, entre otras) con el objetivo de mejorar la capacidad de generalización del modelo durante el entrenamiento.
4. **Entrenamiento del modelo:** A partir del dataset preparado, la plataforma entrena automáticamente un modelo de detección basado en arquitecturas modernas de visión artificial (comúnmente derivadas de la familia YOLO), utilizando frameworks de deep learning como PyTorch en su infraestructura interna.
5. **Despliegue del modelo:** Una vez completado el entrenamiento, el modelo puede utilizarse mediante distintos métodos de inferencia, dependiendo de los requerimientos de la aplicación y de la arquitectura del sistema donde se desee integrarlo.

Las plataformas modernas de visión artificial permiten desplegar modelos de detección a través de diversas modalidades. Entre las más habituales se encuentran:

- **Inferencia en la nube (Cloud Inference):** Las imágenes capturadas por el sistema se envían a un servidor remoto donde se ejecuta el modelo de detección. El servidor procesa la imagen y devuelve como respuesta una estructura de datos que contiene las predicciones del modelo, incluyendo la clase del objeto detectado, su nivel de confianza y la ubicación dentro de la imagen.
- **Inferencia local (Edge Inference):** El modelo puede ejecutarse directamente en el dispositivo que captura las imágenes, como una computadora embebida o un sistema de procesamiento local. En este caso el modelo se exporta en un formato optimizado (por ejemplo TensorFlow Lite u ONNX), permitiendo realizar la detección sin necesidad de conexión a un servidor externo.
- **Inferencia mediante API o servicios de inferencia:** Algunas plataformas proporcionan interfaces programables (API) o contenedores de inferencia que permiten integrar el modelo dentro de aplicaciones personalizadas. En este esquema, el sistema de control envía las imágenes al servicio de inferencia y recibe como respuesta los resultados estructurados generados por el modelo.

La elección del método de inferencia depende de factores como la capacidad de procesamiento disponible, los requisitos de latencia del sistema, la conectividad de red y las restricciones de consumo energético del dispositivo donde se despliega el modelo.

El resultado de la inferencia se entrega típicamente en formato estructurado (por ejemplo JSON), lo que facilita su procesamiento posterior por parte del sistema de control. Esta información será utilizada por el controlador para determinar el tipo de pieza detectada y calcular la acción correspondiente que deberá ejecutar el manipulador dentro del sistema automatizado.

5.1.6. Hardware

Para la implementación de sistemas de visión artificial y procesamiento de imágenes, existen diversas opciones de hardware que varían en capacidad de procesamiento, consumo energético, costo y complejidad de implementación. A continuación, se presenta una evaluación de las alternativas más relevantes para el despliegue del presente proyecto.

Opciones Tecnológicas Disponibles

1. Raspberry Pi con Módulo Cámara

- **Características:** Computadora de placa reducida (SBC) con CPU ARM, GPU VideoCore IV y conectividad GPIO.
- **Ventajas:** Balance ideal entre rendimiento y consumo energético. Amplia comunidad de soporte, documentación extensa y compatibilidad con frameworks como TensorFlow Lite. Soporte para HATs (Hardware Attached on Top) que expanden funcionalidades.
- **Desventajas:** Capacidad de procesamiento limitada para modelos complejos en tiempo real.

2. Microcontrolador ESP32 con Módulo de Cámara

- **Características:** Microcontrolador de bajo consumo con conectividad Wi-Fi/Bluetooth. Módulos de cámara OV2640 o similares con interfaz DCMI.
- **Ventajas:** Bajo costo y consumo energético mínimo. Ideal para aplicaciones IoT y edge computing básico.
- **Desventajas:** Capacidad computacional muy limitada. Inviabile para inferencia de modelos de deep learning no optimizados extremadamente.

3. CPU de Propósito General con Webcam

- **Características:** Computadora tradicional (PC/notebook) con webcam USB estándar.
- **Ventajas:** Máximo rendimiento y flexibilidad. Capacidad para ejecutar modelos complejos y entrenar redes neuronales. Compatibilidad con todos los frameworks principales (TensorFlow, PyTorch).
- **Desventajas:** Alto consumo energético, costo elevado y falta de portabilidad. Sobredimensionado para despliegue embebido.

Expansión mediante HATs para Raspberry Pi

Los HATs (Hardware Attached on Top) son placas de expansión que se conectan directamente al header GPIO de la Raspberry Pi, permitiendo añadir funcionalidades específicas sin hardware adicional complejo. Para aplicaciones de visión artificial, existen HATs especializados que ofrecen:

- **Aceleración por FPGA o ASIC:** Chips dedicados para preprocesamiento de imágenes o inferencia de modelos ligeros.
- **Conectividad Adicional:** Puertos Ethernet adicionales, interfaces industriales o controladores para actuadores.
- **Mejora de Potencia:** Reguladores de voltaje para sistemas que requieren mayor estabilidad con periféricos.

Decisión Tecnológica y Justificación

Para el presente proyecto se selecciona una **Raspberry Pi como plataforma de control principal del sistema**. Este dispositivo actuará como nodo de integración entre el sistema de adquisición de imágenes, el módulo de visión artificial y los elementos de actuación robótica.

A diferencia de otras implementaciones basadas en cámaras dedicadas para Raspberry Pi (como el módulo Raspi-Cam), en este proyecto se utilizará la **cámara integrada en el manipulador robótico**. Este enfoque permite capturar imágenes directamente desde el punto de vista del sistema de manipulación, simplificando la geometría del sistema y facilitando la relación entre la posición detectada en la imagen y las coordenadas de trabajo del manipulador.

El manipulador robótico que formará parte del sistema se describirá en detalle en una sección posterior, donde se analizarán las distintas alternativas de implementación del mecanismo de clasificación de piezas.

La elección de la Raspberry Pi se fundamenta en los siguientes criterios:

1. **Capacidad de integración:** La Raspberry Pi ofrece múltiples interfaces de comunicación (USB, UART, I2C, SPI y Ethernet/WiFi), lo que facilita la integración con dispositivos externos como el manipulador robótico, sensores auxiliares o microcontroladores encargados de subsistemas mecánicos.
2. **Ecosistema de desarrollo maduro:** La amplia disponibilidad de bibliotecas, herramientas de desarrollo y documentación permite implementar rápidamente sistemas que combinan visión artificial, comunicación con hardware y control de dispositivos.
3. **Capacidad suficiente para tareas de coordinación del sistema:** Si bien la Raspberry Pi posee capacidad para ejecutar modelos de visión artificial de forma local, en este proyecto su función principal será la coordinación del flujo de información entre los distintos módulos del sistema, incluyendo la captura de imágenes, el envío de datos al sistema de inferencia y el procesamiento de los resultados obtenidos.

En relación con los módulos de expansión conocidos como HAT (*Hardware Attached on Top*), no se considera necesario incorporar aceleradores de hardware para inferencia en la etapa inicial del proyecto. Esto se debe a que el procesamiento principal del modelo de visión artificial no se realizará directamente en la Raspberry Pi, sino mediante un servicio de inferencia que devuelve como resultado una estructura de datos (por ejemplo en formato JSON) con la información relevante de detección y clasificación.

De esta manera, la Raspberry Pi se utiliza principalmente como dispositivo de adquisición de imágenes, procesamiento de resultados y control del sistema robótico, reduciendo los requerimientos computacionales locales y simplificando la arquitectura hardware del sistema.

5.2. Calibración cámara-robot

Para que el manipulador robótico pueda interactuar físicamente con las piezas detectadas por el sistema de visión artificial, es necesario establecer una relación geométrica entre el sistema de coordenadas de la imagen y el sistema de coordenadas del robot.

Las imágenes capturadas por la cámara se expresan naturalmente en coordenadas de píxel dentro del plano de la imagen. Sin embargo, el manipulador robótico opera en un sistema

de coordenadas cartesianas definido en su espacio de trabajo. Por lo tanto, resulta necesario realizar un proceso de calibración que permita transformar las coordenadas obtenidas en la imagen en posiciones físicas alcanzables por el robot.

Este proceso se conoce comúnmente como calibración cámara-robot (camera-robot calibration) y constituye un problema fundamental en sistemas de manipulación guiada por visión. En términos generales, el objetivo es estimar una transformación geométrica que relacione los puntos observados en la imagen con sus posiciones correspondientes en el plano de trabajo del robot.

Dependiendo de la configuración geométrica del sistema, esta relación puede modelarse mediante transformaciones afines o proyectivas. En aplicaciones donde la cámara observa un plano aproximadamente paralelo al plano de trabajo del robot, es común emplear una transformación conocida como homografía planar, la cual permite mapear coordenadas bidimensionales de la imagen hacia coordenadas físicas en el plano de operación.

Una vez estimada esta transformación mediante un proceso de calibración previo, el sistema puede convertir automáticamente las posiciones detectadas por el modelo de visión artificial en coordenadas que el manipulador robótico puede utilizar para ejecutar las acciones de manipulación robótica.

De esta manera, la calibración constituye el vínculo fundamental entre la etapa de percepción visual y la ejecución física de acciones dentro del sistema automatizado.

5.3. Sistema de alimentación y posicionamiento de piezas

El sistema de alimentación tiene como función suministrar las piezas de manera controlada hacia la zona de inspección visual, garantizando que el módulo de visión pueda capturar imágenes individuales y correctamente posicionadas. Para esta etapa se evaluaron dos alternativas de implementación, considerando criterios de simplicidad mecánica, controlabilidad y viabilidad experimental.

5.3.1. Sistema de posicionamiento por vibración

Esta alternativa consiste en utilizar un recipiente o canal vibratorio que permita el desplazamiento progresivo de las piezas mediante excitación mecánica. La vibración inducida genera un movimiento aleatorio pero direccional que facilita la separación parcial de los componentes, guiándolos hacia una zona de salida controlada.

Ventajas:

- **Simplicidad mecánica:** No requiere mecanismos complejos de transmisión.
- **Bajo número de actuadores:** Puede implementarse mediante un único motor vibrador.
- **Inspiración industrial:** Los alimentadores vibratorios son ampliamente utilizados en sistemas automatizados de clasificación.

Desventajas/Consideraciones:

- **Control limitado del posicionamiento:** La orientación final de las piezas puede resultar impredecible.
- **Dificultad de sincronización:** Puede requerir sensores adicionales para garantizar la presencia individual de cada componente en la zona de inspección.
- **Ajuste experimental complejo:** La frecuencia y amplitud de vibración deben calibrarse cuidadosamente según el tipo de pieza.

5.3.2. Sistema de cinta transportadora motorizada

La segunda alternativa contempla la implementación de una tolva de alimentación por gravedad que descarga las piezas sobre una cinta transportadora motorizada. La cinta, accionada mediante un motor paso a paso controlado por un microcontrolador dedicado, permite desplazar las piezas de manera controlada hasta una zona fija de inspección.

En este esquema, el sistema puede detener la cinta cuando se detecta la presencia de una pieza en el área de captura, permitiendo la adquisición de imagen y posterior manipulación robótica.

Ventajas:

- **Mayor control del movimiento:** Permite regular velocidad y posicionamiento con mayor precisión.
- **Facilidad de sincronización:** El transporte puede detenerse exactamente durante la captura de imagen.
- **Arquitectura modular:** Puede implementarse como un subsistema independiente controlado por un microcontrolador auxiliar.

Desventajas/Consideraciones:

- **Mayor complejidad mecánica:** Requiere sistema de transmisión, estructura y tensado adecuado.
- **Diseño estructural adicional:** Implica mayor tiempo de construcción y calibración inicial.

5.3.3. Consideraciones de selección

Ambas alternativas presentan ventajas técnicas y limitaciones particulares. La elección final del mecanismo de alimentación se definirá en función de pruebas experimentales, estabilidad del posicionamiento obtenido y facilidad de integración con el sistema de visión y el manipulador robótico. Este enfoque permite mantener flexibilidad de diseño durante la etapa de implementación práctica del proyecto.

5.4. Sistema de selector/sorter

Para la etapa de selección y clasificación física de las piezas identificadas por el sistema de visión, se evaluaron tres alternativas de diseño, considerando factores como complejidad técnica, costo, integración pedagógica y viabilidad de implementación.

5.4.1. Robot pick and place

Utilización de un manipulador robótico articulado capaz de ejecutar movimientos controlados en múltiples grados de libertad para realizar operaciones de toma y colocación (*pick and place*). Incluiría efectores finales (*grippers*) capaces de manipular los distintos tipos de piezas del kit VEX.

Ventajas:

- **Precisión y Velocidad:** Potencialmente alto rendimiento en la manipulación, con movimientos repetibles y controlados.
- **Flexibilidad de Diseño:** Se puede optimizar específicamente para la tarea y el espacio disponible, adaptando tanto la cinemática como los efectores finales.

Desventajas/Consideraciones:

- **Alto Costo:** Los actuadores de precisión y controladores especializados son costosos, aunque en este caso puede mitigarse dada la disponibilidad de equipamiento robótico educativo.

5.4.2. Diseño mecanismo dedicado

Un mecanismo diseñado desde cero en software CAD (por ejemplo, SolidWorks o Fusion 360), fabricado mediante técnicas de mecanizado o impresión 3D, accionado por servomotores o motores paso a paso controlados por un microcontrolador (como un PIC o ESP32). El diseño sería un mecanismo dedicado, como un selector rotativo o un clasificador por forma.

Ventajas:

- **Personalización Total:** El diseño se adapta perfectamente a las piezas VEX.
- **Componentes de Bajo Costo:** Microcontroladores y servomotores son accesibles y de fácil integración.

Desventajas/Consideraciones:

- **Tiempo de Desarrollo Extendido:** Diseñar, imprimir, probar y refinar un mecanismo confiable consume mucho tiempo y requiere iteraciones.
- **Riesgo de Falta de Robustez:** Los prototipos impresos en 3D pueden no ser suficientemente duraderos o precisos para operación continua.
- **Complejidad Mecánica:** Aún requiere un esfuerzo significativo en ingeniería mecánica y ajuste fino de tolerancias.

5.4.3. Kit VEX IQ

Utilizar los componentes del kit VEX (motores, sensores, vigas, engranajes) para construir el mecanismo selector. El sistema de visión en la Raspberry Pi enviaría comandos a un microcontrolador VEX que controle los actuadores del kit.

Ventajas:

- **Coherencia y Relevancia Pedagógica:** Es la opción con mayor valor educativo. Los estudiantes ven una aplicación tangible y avanzada de los mismos componentes que usan en sus prácticas, motivándolos al demostrar el potencial completo del kit.
- **Fiabilidad Mecánica:** Los componentes VEX están diseñados para aplicaciones robóticas, son robustos y se integran perfectamente entre sí.
- **Menor Tiempo de Desarrollo:** No es necesario diseñar ni fabricar partes mecánicas desde cero; se ensambla con partes conocidas.
- **Bajo Costo Marginal:** Si la institución ya cuenta con los kits, el costo adicional es mínimo.

Desventajas/Consideraciones:

- **Limitaciones Mecánicas:** El rango de movimientos y la velocidad pueden estar limitados por los componentes estándar del kit.
- **Entorno Cerrado:** El ecosistema VEX IQ es altamente blindado, impidiendo la comunicación directa con microcontroladores externos y restringiendo el control de sus módulos mediante hardware o protocolos ajenos a su entorno propietario.
- **Requiere Creatividad:** Diseñar un mecanismo efectivo dentro de las limitaciones impuestas por el ecosistema cerrado del kit exige soluciones no convencionales y, en muchos casos, poco prácticas.

5.4.4. Elección y Justificación

Se ha seleccionado la **Opción 1: Robot *pick and place***.

Esta elección se basa en criterios de viabilidad técnica, coherencia con el perfil de un proyecto de ingeniería electrónica y la disponibilidad de equipamiento. Actualmente se cuenta con la posibilidad de utilizar en préstamo un brazo robótico colaborativo de carácter educativo, se trata del Dobot Magician Lite y permite concentrar los esfuerzos del proyecto en el desarrollo del sistema de visión y su integración con el control del manipulador.

Desde una perspectiva académica, esta opción presenta un desafío más alineado con los objetivos formativos de la carrera: la integración entre el procesamiento de imágenes, la toma de decisiones y el control preciso de un sistema robótico real. Este enfoque favorece

el análisis de la comunicación entre subsistemas, la calibración de coordenadas espaciales y la sincronización entre percepción y acción, aspectos fundamentales en el campo de la automatización avanzada.

A diferencia de las alternativas que implican un extenso trabajo mecánico o dependencias de entornos cerrados, el uso de un brazo robótico existente permite centrar el esfuerzo en la parte electrónica, de control y de software, optimizando los recursos disponibles y evitando la complejidad estructural innecesaria.

En consecuencia, la elección del sistema *pick and place* ofrece un equilibrio adecuado entre factibilidad, nivel técnico y valor académico, permitiendo demostrar de forma clara la convergencia entre visión artificial, inteligencia artificial embebida y control robótico.

5.5. Interfaces de comunicación del sistema

El sistema propuesto integra distintos subsistemas que requieren intercambiar información durante la operación del proceso de clasificación automática. En lugar de utilizar un protocolo de comunicación complejo entre múltiples microcontroladores, la arquitectura adoptada se basa en una Raspberry Pi que actúa como nodo central de control, coordinando la adquisición de imágenes, el procesamiento de resultados y la ejecución de acciones físicas.

5.5.1. Comunicación con el manipulador robótico

La comunicación entre la Raspberry Pi y el manipulador robótico Dobot Magician Lite se realizará mediante una interfaz USB. En este esquema, el robot se presenta ante el sistema operativo como un dispositivo de comunicación serial virtual, permitiendo el envío de comandos de control desde la Raspberry Pi hacia el controlador del robot.

A través de esta interfaz se transmiten las instrucciones necesarias para ejecutar las acciones de manipulación. La implementación concreta de estos comandos se realizará utilizando las librerías y herramientas provistas por el fabricante del manipulador.

5.5.2. Control del sistema de transporte

El control del movimiento del sistema de alimentación se realizará mediante señales digitales simples desde los pines GPIO de la Raspberry Pi hacia el controlador del sistema de transporte. De esta manera, la Raspberry Pi podrá habilitar o deshabilitar el avance de las piezas en función del estado del proceso de inspección y manipulación.

Este esquema de control permite sincronizar el transporte de piezas con la captura de

imágenes y la ejecución de movimientos del manipulador robótico, manteniendo una arquitectura simple y robusta.

5.5.3. Procesamiento de resultados de inferencia

El modelo de visión artificial utilizado en el proyecto entrega los resultados de detección y clasificación en un formato estructurado, típicamente representado mediante JSON (JavaScript Object Notation). Este formato permite encapsular de manera clara la información relevante obtenida durante el proceso de inferencia.

Entre los datos devueltos por el sistema de visión se incluyen generalmente:

- La clase o tipo de pieza identificada.
- El nivel de confianza de la predicción.
- La posición de la pieza dentro de la imagen (por ejemplo, mediante coordenadas del centro o cuadros delimitadores).

La Raspberry Pi procesa esta información para determinar la acción correspondiente dentro del sistema. En particular, la posición detectada en la imagen se utiliza para estimar la ubicación de la pieza en el espacio de trabajo del robot, permitiendo generar los comandos necesarios para su manipulación y clasificación.

```
{
  "predictions": [
    {
      "class": "gear_36",
      "confidence": 0.91,
      "x": 312,
      "y": 210,
      "width": 84,
      "height": 79
    }
  ]
}
```

6. Plan de acción

6.1. Diagrama del sistema

La arquitectura general del sistema se representa mediante un diagrama en bloques (Fig. 10), el cual integra tres subsistemas principales: (i) alimentación y transporte de piezas hacia la zona de inspección, (ii) adquisición y procesamiento de imágenes con un modelo de detección de objetos basado en inteligencia artificial, y (iii) ejecución física de la acción mediante un manipulador robótico tipo *pick-and-place*. Adicionalmente, puede incorporarse un microcontrolador auxiliar para el control del sistema de transporte en caso de implementarse la alternativa de cinta transportadora.




Fig. 10: Arquitectura del sistema

6.1.1. Adquisición y procesamiento de imágenes

Una cámara ubicada en la zona de inspección captura imágenes de las piezas de forma individual. Para mejorar la repetibilidad del proceso, el sistema de alimentación debe asegurar que durante la captura la pieza permanezca inmóvil (por ejemplo, deteniendo temporalmente

la cinta transportadora o estabilizando la pieza en una región de salida del alimentador). La Raspberry Pi realizará el preprocesamiento básico de la imagen (recorte, redimensionamiento y normalización) previo a la etapa de inferencia.

6.1.2. Detección de objetos y clasificación mediante modelo de inteligencia artificial

Cada imagen preprocesada es analizada por un modelo de detección de objetos previamente entrenado, capaz de identificar el tipo de pieza. Dependiendo de la estrategia de implementación, la inferencia podrá ejecutarse localmente en la Raspberry Pi (por ejemplo, mediante un modelo optimizado para despliegue embebido) o mediante un servicio de inferencia que entregue el resultado en formato estructurado.

Como salida de esta etapa se obtiene, para cada pieza, un conjunto de datos mínimos: (i) clase o tipo de componente identificado, y (ii) información geométrica asociada a su ubicación en la imagen (por ejemplo, coordenadas del centro o región delimitadora), junto con un indicador de confianza.

6.1.3. Integración y decisión de control

A partir del resultado de clasificación, la Raspberry Pi decodifica la información estructurada (por ejemplo, en formato JSON) y determina la acción a ejecutar. En particular, se calcula la posición objetivo en el espacio de trabajo del robot mediante un proceso de calibración que relaciona el sistema de coordenadas de la imagen con el sistema de coordenadas del manipulador.

Luego, se generan los comandos necesarios para que el brazo robótico se desplace hacia la posición de toma (*pick*), realice la captura de la pieza y la traslade hacia el compartimento correspondiente del kit (*place*). La comunicación con el manipulador se realizará a través de una interfaz USB, típicamente implementada como un canal de comunicación serial sobre USB.

En paralelo, si se adopta el subsistema de cinta transportadora, la Raspberry Pi podrá coordinar el avance y la detención del transporte mediante un microcontrolador auxiliar, sincronizando la alimentación con el ciclo de inspección y manipulación.

6.1.4. Ejecución de la acción

El manipulador robótico ejecuta una secuencia de movimientos compuesta por: posicionamiento en la zona de toma, descenso controlado hacia la pieza, activación del efector final

para sujetarla, elevación y desplazamiento hacia la ubicación destino, liberación de la pieza y retorno a una posición inicial. La ubicación destino se selecciona en función del tipo de pieza identificado, utilizando un mapa predefinido de compartimentos.

En caso de que una pieza no sea reconocida con un nivel de confianza suficiente, o no corresponda a ninguna clase prevista, el sistema podrá dirigirla a una zona de descarte, de acuerdo con los criterios definidos para la etapa de implementación práctica.

6.2. Entregables

El presente proyecto contempla la entrega de los siguientes productos y documentos, los cuales demuestran el cumplimiento de los objetivos planteados y constituyen el resultado tangible de la investigación y el desarrollo realizado.

6.2.1. Documentación Técnica y Académica

1. **Informe de Anteproyecto:** Es el presente documento que contiene la definición inicial del problema, el estado del arte, los objetivos generales y específicos, la metodología de trabajo propuesta y el plan de acción con su cronograma correspondiente.
2. **Informe Final:** Documento exhaustivo que describe en detalle el desarrollo completo del proyecto. Incluirá:
 - Exposición de la metodología implementada.
 - Descripción de los diseños hardware y software realizados.
 - Análisis de los resultados obtenidos, incluyendo métricas de rendimiento del modelo de detección de objetos y clasificación, y eficiencia del sistema.
 - Conclusiones derivadas del trabajo y propuestas de líneas futuras de desarrollo.

6.2.2. Productos de Software y Modelos

1. **Código Fuente Completo:** El software desarrollado, organizado en un repositorio estructurado que incluye:
 - Scripts para el preprocesamiento de datos y entrenamiento del modelo.
 - Programa principal para la Raspberry Pi, encargado de la captura de imágenes, inferencia y comunicación.
 - Programa del microcontrolador, responsable del control del mecanismo selector.

- Instrucciones claras para su instalación, configuración y ejecución.

6.2.3. Prototipo Funcional

Sistema de Clasificación Automatizado: Un prototipo físico completamente integrado y funcional, compuesto por:

- Estación de adquisición de imágenes (Raspberry Pi con cámara module).
- Sistema robótico de manipulación basado en brazo pick-and-place.
- Sistema de control que demuestra el flujo completo: desde la adquisición de la imagen hasta la clasificación y ordenamiento físico de la pieza.

6.2.4. Materiales Complementarios

1. **Conjunto de Datos (Dataset):** La colección de imágenes de piezas VEX etiquetadas utilizadas para el entrenamiento y validación del modelo de aprendizaje profundo. Este recurso quedará a disposición para futuros trabajos académicos o desarrollos.
2. **Video Demostrativo:** Una grabación que evidencia el funcionamiento del prototipo en tiempo real, mostrando su capacidad para identificar, clasificar y organizar piezas de forma autónoma.